

**Laporan Akhir Tugas Besar Rekayasa Fitur:
Perbandingan Sentimen Multi-Label Pada Lirik Lagu Album
“Nonfiksi” Dan “Sentimental” Karya Juicy Luicy**

Disusun Untuk Memenuhi Tugas Besar Mata Kuliah Rekayasa Fitur

Dosen Pengampu: Galih Hermawan, S.Kom, M.T



Disusun Oleh :

Fathya Nurulhasanah	10123190
Mutiara Annuur	10123177
Annisa Nuraeni	10123193

**TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS KOMPUTER INDONESIA**

2026

DAFTAR ISI

DAFTAR ISI.....	2
ABSTRAK.....	3
1.1 Latar Belakang.....	4
1.2 Tujuan.....	4
BAB II: TINJAUAN PUSTAKA.....	5
2.1 Pra-pemrosesan Teks dan Custom Stopword.....	5
2.2 Zero-Shot Classification.....	5
2.3 TF-IDF dan N-Grams.....	5
2.4 Klasifikasi Sentimen Multi-Label dengan Naive Bayes.....	5
2.5 Rekayasa Fitur Struktural (Structural Feature Engineering).....	6
BAB III: METODOLOGI.....	7
3.1 Dataset dan Teknik Pengumpulan Data.....	7
3.2 Pra-pemrosesan Data (Text Preprocessing).....	8
3.3 Pemodelan.....	8
3.4 Evaluasi.....	10
3.5 Kontribusi Anggota.....	10
BAB IV: HASIL DAN PEMBAHASAN.....	11
4.1 Hasil Eksplorasi Data (EDA) Fitur Struktural.....	11
4.2 Evaluasi Model Klasifikasi.....	13
4.3 Analisis Karakteristik Emosi per Album.....	15
4.4 Analisis Komposisi Sentimen Tingkat Lagu.....	16
4.5 Keterbatasan.....	18
4.6 Implementasi Prototipe Antarmuka (Deployment).....	18
BAB V: KESIMPULAN.....	20

ABSTRAK

Laporan ini menyajikan proses rekayasa fitur dan klasifikasi teks (*Natural Language Processing*) untuk membandingkan karakteristik sentimen multi-label pada lirik lagu Juicy Luicy dari album "Non Fiksi" dan "Sentimental". Pengumpulan 812 baris observasi data lirik dilakukan secara otomatis melalui ekstraksi API. Karena dataset mentah tidak memiliki label target, proses anotasi otomatis dilakukan menggunakan metode *Zero-Shot Classification* berbasis AI. Tahapan pra-pemrosesan teks meliputi *case folding*, pembersihan tanda baca, tokenisasi, dan *custom stopword removal* yang dirancang khusus untuk mempertahankan konteks kata negasi pada lirik. Rekayasa fitur dilakukan melalui dua tahap: ekstraksi fitur teks menggunakan pembobotan TF-IDF (*N-Grams*) dan ekstraksi fitur struktural (jumlah kata, karakter, dan interaksi) yang dinormalisasi. Kedua representasi tersebut digabungkan (*feature fusion*) dan diklasifikasikan menggunakan algoritma Multinomial Naive Bayes (MNB) dengan pendekatan *OneVsRest*. Hasil pengujian model menunjukkan kinerja yang sangat baik dengan tingkat kesalahan prediksi (*Hamming Loss*) yang rendah sebesar 0.1580 dan nilai *F1-Score (Micro)* sebesar 0.6656. Analisis visual akhir membuktikan bahwa album "Sentimental" memiliki intensitas emosi rindu dan melankolis yang jauh lebih tajam, sementara album "Non Fiksi" menampilkan komposisi narasi emosi yang lebih dinamis dan merata.

BAB I PENDAHULUAN

1.1 Latar Belakang

Data teks merupakan salah satu bentuk data tidak terstruktur yang paling masif dihasilkan di era digital. Salah satu bentuk teks yang menarik untuk dianalisis adalah lirik lagu, karena lirik lagu memuat representasi emosi, tema, dan gaya bahasa dari penyanyinya secara langsung. Lirik lagu seringkali mengandung lebih dari satu emosi pada saat yang bersamaan, sehingga pendekatan klasifikasi sentimen multi-label sangat relevan untuk digunakan. Akan tetapi, data teks mentah tidak dapat diproses secara langsung oleh algoritma pembelajaran mesin. Diperlukan serangkaian tahapan pra-pemrosesan dan rekayasa fitur (*feature engineering*) tingkat lanjut, baik secara semantik maupun struktural, untuk mentransformasikan teks bahasa Indonesia menjadi matriks numerik yang kaya akan informasi agar siap diklasifikasikan.

1.2 Tujuan

Berdasarkan latar belakang yang telah dipaparkan sebelumnya, tujuan dari penelitian ini adalah sebagai berikut:

1. Melakukan tahapan pra-pemrosesan teks yang berfokus pada pelestarian konteks emosional lirik lagu.
2. Mengimplementasikan anotasi data otomatis menggunakan metode *Zero-Shot Classification* untuk membentuk label target multi-label.
3. Melakukan rekayasa fitur dengan menggabungkan ekstraksi teks (TF-IDF) dan fitur struktural lirik untuk mengoptimalkan kinerja model.
4. Membangun dan mengevaluasi model klasifikasi Multinomial Naive Bayes untuk membandingkan komposisi sentimen antara album "Non Fiksi" dan "Sentimental".

BAB II: TINJAUAN PUSTAKA

2.1 Pra-pemrosesan Teks dan Custom Stopword

Pra-pemrosesan teks adalah tahapan persiapan data yang bertujuan membuang elemen tanpa nilai semantik. Pada analisis lirik lagu, penghapusan kata hubung (*stopword removal*) harus disesuaikan (*custom*) agar kata ganti subjek dan kata negasi (seperti "tidak" atau "tak") tidak terhapus, sehingga konteks emosi tetap terjaga.

2.2 Zero-Shot Classification

Zero-Shot Classification adalah teknik dalam *Machine Learning* di mana sebuah model *pre-trained* (seperti berbasis arsitektur Transformer) dapat mengklasifikasikan teks ke dalam kategori tertentu tanpa memerlukan data latih berlabel sebelumnya. Metode ini sangat efektif untuk pelabelan otomatis (*automated data annotation*) pada dataset mentah.

2.3 TF-IDF dan N-Grams

Term Frequency-Inverse Document Frequency (TF-IDF) adalah metode pembobotan yang mengevaluasi seberapa penting sebuah kata dalam suatu dokumen relatif terhadap kumpulan dokumen lainnya. Penggunaan N-Grams (seperti bigram) memungkinkan TF-IDF menangkap frasa gabungan dua kata, memberikan pemahaman konteks yang lebih baik dibanding pendekatan kata tunggal.

2.4 Klasifikasi Sentimen Multi-Label dengan Naive Bayes

Klasifikasi multi-label mengizinkan penetapan lebih dari satu label emosi pada satu baris data. Multinomial Naive Bayes adalah algoritma probabilistik yang efisien untuk data teks. Untuk menangani multi-label, algoritma ini diadaptasi menggunakan strategi *OneVsRest*, di mana model dilatih untuk memprediksi setiap label secara independen.

2.5 Rekayasa Fitur Struktural (Structural Feature Engineering)

Selain ekstraksi fitur dari makna kata, informasi pada teks juga dapat digali melalui struktur fisik kalimatnya. Rekayasa fitur struktural melibatkan transformasi karakteristik teks—seperti menghitung jumlah kata, rata-rata panjang karakter, dan jumlah tanda baca—menjadi metrik numerik. Pada analisis lirik lagu, fitur ini berguna untuk melihat kompleksitas susunan kalimat atau tempo penceritaan dari sebuah lagu.

BAB III: METODOLOGI

3.1 Dataset dan Teknik Pengumpulan Data

Dataset yang digunakan dalam proyek ini difokuskan pada lirik lagu dari artis Juicy Lucy, secara spesifik membandingkan karakteristik emosional album "Non Fiksi" dan "Sentimental". Proses pengumpulan data (data crawling) dilakukan secara otomatis menggunakan bahasa pemrograman Python di platform Google Colab.

Rincian pengumpulan dan karakteristik dataset meliputi:

a. Mekanisme Ekstraksi (API)

Data ditarik menggunakan metode *HTTP GET request* ke *endpoint* LRCLIB API ([<https://lrclib.net/>])(<https://lrclib.net/>). Respon API yang berformat JSON diekstraksi untuk mendapatkan teks lirik (*plain lyrics*) beserta meta datanya untuk total 25 judul lagu.

b. Pemecahan Data dan Filter Dasar

Teks lirik yang panjang dipecah berdasarkan baris baru (*newline*) agar data teks dapat dikelola secara granular per baris. Pada tahap ini, diterapkan filter dasar untuk menghapus penanda struktur lagu (seperti [Verse] atau [Chorus]) serta mengabaikan teks kosong agar observasi memiliki konteks emosi yang jelas.

c. Etika Akses Data (Rate Limiting)

Penarikan data dirancang dengan menerapkan jeda waktu (*delay*) antar permintaan. Hal ini dilakukan untuk mematuhi etika penggunaan API publik dan menjaga stabilitas koneksi tanpa membebani server penyedia data.

d. Karakteristik Akhir Dataset

Seluruh baris lirik yang berhasil diekstraksi disimpan dalam format CSV. Dataset mentah (*raw data*) ini terdiri dari 812 baris observasi (sebelum pra-pemrosesan NLP) dengan 4 atribut utama: Artis, Album, Judul_Lagu, dan Baris_Lirik. Kondisi awal data ini merupakan *unannotated data* (belum memiliki label target sentimen).

3.2 Pra-pemrosesan Data (Text Preprocessing)

Sebelum fitur diekstraksi, data teks mentah harus dibersihkan dan distandarisasi agar tidak menghasilkan *noise* pada model. Tahapan ini dilakukan secara komprehensif melalui langkah-langkah berikut:

a. Data Cleansing & Formatting:

Menggunakan pustaka *Regular Expression* (Regex) untuk menghapus karakter non-alfanumerik, simbol, dan angka yang tidak relevan dengan konteks emosi. Selanjutnya, dilakukan *case folding* untuk menyeragamkan seluruh teks menjadi huruf kecil (*lowercase*), serta *stripping* untuk menghapus spasi berlebih (*whitespace*).

b. Tokenisasi (Tokenization)

Memecah kalimat utuh menjadi potongan kata-kata individual (token) untuk mempermudah analisis frekuensi di tahap selanjutnya.

c. Custom Stopword Removal

Menghapus kata hubung (seperti "di", "ke", "dari") yang tidak memiliki nilai semantik. Secara khusus, dilakukan modifikasi (*custom*) pada kamus *stopword* agar kata ganti subjek ("aku", "kau") dan kata negasi ("tidak", "tak", "bukan") dipertahankan, karena elemen tersebut sangat krusial dalam membentuk arah sentimen pada lirik lagu.

d. Anotasi Data Otomatis (Ground Truth Generation)

Menggunakan metode *Zero-Shot Classification* dari model *pre-trained* MDeBERTa untuk menyuntikkan label target secara otomatis berdasarkan konteks kalimat utuh, mengubah status data dari *unannotated* menjadi siap latih dengan 7 kategori sentimen multi-label.

3.3 Pemodelan

Tahap ini merupakan inti dari penyelesaian masalah, di mana data teks yang telah bersih ditransformasikan ke dalam representasi matematis, diperkaya fiturnya, dan akhirnya dimasukkan ke dalam algoritma *Machine Learning* untuk proses klasifikasi. Tahapan ini dibagi menjadi dua bagian utama:

1. Rekayasa Fitur (Feature Engineering)

a. Ekstraksi Fitur Teks (TF-IDF N-Grams)

Mengubah representasi teks menjadi matriks bobot numerik menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF). Parameter *N-Grams* diatur pada rentang (1, 2) untuk mengekstraksi unigram (satu kata) dan bigram (kombinasi dua kata berurutan). Hal ini memungkinkan model untuk membaca frasa utuh seperti "tak mungkin" sebagai satu kesatuan fitur, bukan dua kata yang terpisah.

b. Pembentukan Fitur Struktural (Structural Features)

Selain fitur semantik kata, dilakukan ekstraksi informasi berdasarkan struktur fisik tiap baris lirik. Dibentuk lima fitur numerik baru, yaitu: jumlah kata (*word count*), jumlah karakter (*character count*), rata-rata panjang kata, jumlah tanda baca, dan fitur interaksi (perkalian antara kata dan karakter) untuk merepresentasikan kompleksitas kalimat.

c. Feature Scaling dan Penggabungan (Feature Fusion)

Karena fitur struktural memiliki rentang skala angka yang jauh lebih besar dibandingkan matriks bobot TF-IDF (yang berada di rentang 0-1), dilakukan normalisasi data menggunakan *MinMaxScaler*. Setelah skala diseragamkan, fitur struktural dan fitur TF-IDF digabungkan (*concatenate*) menjadi satu *dataframe* utuh yang kaya akan dimensi informasi, siap untuk dieksekusi oleh model klasifikasi.

2. Pemodelan Klasifikasi

Algoritma pembelajaran mesin yang digunakan untuk mengklasifikasikan *dataframe* gabungan tersebut adalah Multinomial Naive Bayes (MNB). Model probabilistik ini dipilih karena secara komputasi sangat efisien dan handal dalam menangani sebaran data teks berdimensi tinggi yang dihasilkan dari TF-IDF. Karena permasalahan ini menuntut prediksi sentimen *multi-label* (di mana satu baris lirik bisa memiliki lebih dari satu emosi secara bersamaan), algoritma MNB dibungkus menggunakan pendekatan meta-estimator OneVsRest. Strategi ini melatih satu model pengklasifikasi independen untuk setiap kategori label emosi, sehingga memungkinkan model mengenali kombinasi sentimen yang kompleks.

3.4 Evaluasi

Mengingat ini adalah kasus klasifikasi multi-label, matrix akurasi tradisional kurang relevan digunakan karena dapat memberikan penilaian bias jika model hanya menebak sebagian label dengan benar. Oleh karena itu, metrik evaluasi yang digunakan adalah:

a. Hamming Loss

Mengukur persentase prediksi label yang salah atau meleset dari total keseluruhan prediksi. Semakin mendekati nilai 0, semakin baik performa model.

b. F1-Score (Micro dan Macro)

Digunakan untuk mencari keseimbangan (rata-rata harmonik) antara tingkat Precision dan Recall, yang sangat penting ketika distribusi emosi pada dataset tidak seimbang (imbalanced data).

3.5 Kontribusi Anggota

Dalam penyelesaian tugas besar ini, pembagian peran dan tanggung jawab teknis didistribusikan secara merata kepada seluruh anggota kelompok. Rincian kontribusi masing-masing anggota dapat dilihat pada Tabel 3.1 berikut:

Tabel 3.1 Rincian Kontribusi Anggota Kelompok


Nim - Nama Anggota	Tugas yang dilakukan
10123190 - Fathya Nurulhasanah	Bertanggung jawab pada tahap pengumpulan data melalui API, pra-pemrosesan teks dasar, dan anotasi (pelabelan) data.
10123177 - Mutiara Annuur	Bertanggung jawab pada tahap rekayasa fitur (ekstraksi teks dan struktural), serta pemodelan algoritma klasifikasi Naive Bayes.
10123193 - Annisa Nuraeni	Bertanggung jawab melakukan evaluasi kinerja model, menghitung metrik pengujian, serta membuat visualisasi data hasil analisis.

BAB IV: HASIL DAN PEMBAHASAN

4.1 Hasil Eksplorasi Data (EDA) Fitur Struktural

Sebelum matriks fitur digabungkan dan diklasifikasikan oleh model, dilakukan tahap Eksplorasi Data (EDA) terhadap fitur struktural yang telah diekstraksi. Hal ini bertujuan untuk memahami karakteristik dasar dari lirik lagu Juicy Luicy.


A. Distribusi Dasar Lirik




Gambar 4.1 Distribusi Jumlah Kata dan Boxplot Jumlah Karakter

Berdasarkan visualisasi Histogram (Gambar 4.1 kiri), dapat dilihat bahwa distribusi jumlah kata per baris lirik berpusat pada angka 4 hingga 6 kata. Sementara itu, pada visualisasi Boxplot (Gambar 4.1 kanan), median jumlah karakter per baris lirik berada di angka 25 karakter. Hal ini mengindikasikan bahwa Juicy Luicy cenderung menggunakan potongan kalimat lirik yang pendek, padat, dan *catchy* di setiap barisnya.

B. Perbandingan Struktural Berdasarkan Album dan Lagu




Gambar 4.2 Visualisasi Perbandingan Karakteristik Teks per Album



Gambar 4.3 Top 10 Lagu dengan Rata-rata Jumlah Kata Terbanyak

Dari visualisasi *Bar Chart* (Gambar 4.2), diketahui bahwa dataset yang diekstraksi memiliki ketidakseimbangan jumlah lagu, di mana album "Non Fiksi" menyumbang 13 lagu, sedangkan "Sentimental" 9 lagu. Meskipun begitu, rata-rata panjang kata per baris pada kedua album sangat seimbang (berada di angka rata-rata 4 kata). Berdasarkan *Violin Plot*, sebaran kepadatan lirik di kedua album juga memiliki pola yang hampir identik. Secara spesifik (Gambar 4.3), lagu "Bukan Orangnya" memegang rekor sebagai lagu dengan rata-rata kalimat terpanjang dibandingkan lagu lainnya.

C. Korelasi Antar Fitur Struktural



Gambar 4.4 Heatmap Korelasi Antar Fitur Struktural

Matriks korelasi di atas memvalidasi logika rekayasa fitur yang telah dibangun. Terdapat korelasi positif yang sangat kuat (0.90) antara jumlah_kata dan jumlah_karakter, serta korelasi yang nyaris sempurna (0.96 dan 0.93) antara fitur interaksi dengan fitur dasar penyusunnya. Hal ini membuktikan bahwa fitur struktural yang diciptakan merespon kompleksitas lirik dengan sangat baik dan siap untuk diintegrasikan dengan fitur teks TF-IDF pada tahap pemodelan.

4.2 Evaluasi Model Klasifikasi

Kinerja algoritma Multinomial Naive Bayes (MNB) dalam mengklasifikasikan sentimen multi-label dievaluasi menggunakan data uji (test set) sebesar 20% dari total dataset. Hasil pengujian menunjukkan nilai Hamming Loss sebesar 0.1580, F1-Score (Micro) 0.6656, dan F1-Score (Macro) 0.5367. Rincian performa untuk setiap kelas emosi dapat dilihat pada tabel berikut:

Tabel 4.1 Hasil Classification Report

Kelas	Precision	Recall	F1-Score	Support
Galau/Sedih	1.00	0.28	0.43	29
Harapan/Wondering	1.00	0.13	0.24	30
Kecewa/Marah	0.82	0.58	0.68	48
Netral	1.0	0	0.2	23

	0	. 1 3	3	
Patah Hati/Move On	1.0 0	0 .4 7	0.6 4	49
Rindu/Nostal gia	0.7 4	0 .9 2	0.8 2	96
Romantis/Cin ta	0.8 5	0 .6 8	0.7 5	59
Senang/Baha gia	1.0 0	0 .3 3	0.5 0	33
Micro Average	0.8 2	0 .5 6	0.6 7	36 7
Macro Average	0.9 3	0 .4 4	0.5 4	36 7
Weighted Average	0.8 8	0 .5 6	0.6 2	36 7
Samples Average	0.6 7	0 .5	0.5 6	36 7


		2		
--	--	---	--	--

Berdasarkan metrik di atas, nilai Hamming Loss 0.1580 menunjukkan bahwa persentase kesalahan prediksi model sangat rendah (sekitar 15.8%). Dari tabel *Classification Report*, terlihat model memiliki nilai Precision yang sangat baik (banyak kelas mencapai angka 1.00). Artinya, ketika model memprediksi sebuah lirik memiliki emosi tertentu, prediksi tersebut hampir selalu benar.

Namun, model masih memiliki tantangan pada nilai Recall yang rendah di beberapa kelas (seperti Harapan dan Netral). Hal ini menunjukkan bahwa model cenderung "konservatif" dan berhati-hati dalam menebak label, sehingga ada beberapa emosi yang gagal terdeteksi. Kategori Rindu/Nostalgia menjadi kelas yang paling berhasil diprediksi (F1-Score 0.82) karena memiliki jumlah data dukungan (*support*) yang paling dominan. Secara keseluruhan, model MNB dengan fitur gabungan (TF-IDF dan struktural) sudah cukup memadai untuk memetakan tren sentimen.

4.3 Analisis Karakteristik Emosi per Album

Untuk menjawab tujuan utama proyek, hasil prediksi model divisualisasikan menggunakan *Radar Chart* dan *Heatmap* untuk membandingkan komposisi emosi antara album "Non Fiksi" dan "Sentimental".



Gambar 4.5 Radar Chart Perbandingan Emosi Album

Berdasarkan hasil visualisasi di atas, kedua album menunjukkan konsistensi tema musikal band yang melankolis. Namun, terdapat perbedaan tarikan intensitas yang signifikan:

A. Album "Sentimental" (Garis Biru)

Memiliki tarikan persebaran yang jauh lebih lebar pada kategori emosi melankolis. Terdapat lonjakan yang paling tajam pada kategori Rindu/Nostalgia dan Galau/Sedih. Hal ini membuktikan bahwa album Sentimental dirancang dengan muatan emosional yang lebih mendalam dan secara spesifik berfokus pada tema masa lalu.


B. Album "Non Fiksi" (Garis Merah Muda)

Memiliki sebaran emosi yang sedikit lebih landai dibandingkan Sentimental, namun memimpin pada kategori Netral. Hal ini mengindikasikan bahwa gaya penulisan lirik pada album Non Fiksi lebih condong ke arah penceritaan naratif dibandingkan sekadar luapan emosi langsung.

4.4 Analisis Komposisi Sentimen Tingkat Lagu

Untuk membedah komposisi emosi secara lebih detail (mikro), hasil prediksi disajikan dalam bentuk *Heatmap* persentase emosi pada lagu-lagu di kedua album.


A. Komposisi Sentimen Album "Non Fiksi"



Gambar 4.6 Heatmap Komposisi Sentimen Top Lagu Non Fiksi

Visualisasi *Heatmap* pada album "Non Fiksi" memperlihatkan komposisi sentimen multi-label yang lebih kompleks dan tersebar secara merata. Warna-warna dominan pada kotak tidak hanya menumpuk di satu kategori, melainkan terpecah ke dalam berbagai nuansa emosi, termasuk kategori *Harapan/Wondering*, *Kecewa/Marah*, dan *Netral*. Hal ini menunjukkan bahwa lagu-lagu di album Non Fiksi memiliki struktur penceritaan yang lebih dinamis, di mana tiap lagunya membawa nuansa narasi yang saling berbeda dan kaya akan variasi cerita.

B. Komposisi Sentimen Album "Sentimental"



Gambar 4.7 Heatmap Komposisi Sentimen Lagu pada Album Sentimental

Berkebalikan dengan Non Fiksi, visualisasi *Heatmap* pada album "Sentimental" mempertegas arsitektur lagu yang lebih spesifik. Terlihat konsentrasi warna yang sangat pekat terpusat pada kolom *Rindu/Nostalgia* dan *Galau/Sedih*. Hal ini mengonfirmasi bahwa hampir seluruh lagu di album ini dibangun dengan pondasi kerinduan yang sangat dominan. Konsistensi blok warna yang gelap pada kategori melankolis membuktikan bahwa album Sentimental dirancang dengan fokus tematik yang tajam dan seragam untuk mengekspresikan kemurungan dan memori masa lalu.

4.5 Keterbatasan

Berdasarkan hasil evaluasi dan pembahasan, terdapat beberapa keterbatasan dalam proyek ini yang dapat menjadi ruang perbaikan:

1. Ketidakseimbangan Data (Data Imbalance):
Rendahnya nilai *Recall* pada beberapa kategori emosi disebabkan oleh jumlah kemunculan data (support) yang tidak seimbang (didominasi kelas Rindu). Teknik *oversampling* atau pembobotan kelas dapat diterapkan ke depannya.
2. Ketergantungan pada Anotasi AI:
Pelabelan data awal dilakukan menggunakan *Zero-Shot Classification* dari model pra-latih, bukan oleh pakar manusia. Metafora puitis yang sangat implisit pada lirik lagu mungkin belum terpetakan dengan akurasi semantik 100%.
3. Keterbatasan Algoritma:
Multinomial Naive Bayes dan TF-IDF beroperasi dengan asumsi independensi antar kata (mengabaikan struktur urutan kalimat). Untuk lirik lagu yang kompleks, algoritma berbasis urutan (*sequence-based*) seperti IndoBERT berpotensi memberikan performa yang lebih tajam.


4.6 Implementasi Prototipe Antarmuka (*Deployment*)

Untuk membuktikan bahwa tahapan rekayasa fitur dan pemodelan Machine Learning yang telah dibangun dapat berjalan secara fungsional, penelitian ini juga mengimplementasikan model ke dalam bentuk purwarupa (prototype) aplikasi web interaktif. Implementasi ini dibangun menggunakan framework antarmuka Streamlit.



Gambar 4.8 Tampilan Antarmuka Mesin Analisis Sentimen Lirik

Radar Chart Komposisi Sentimen



Detail Rekayasa Fitur

Matriks fitur yang berhasil diekstrak dan diproses oleh model:

- Dimensi Vektor TF-IDF: 1000 fitur N-Grams
- Dimensi Fitur Struktural: 5 metrik fisik
- Total Matriks Gabungan: 1005 fitur (Feature Fusion)
- Kecocokan Kamus Model: 5 frasa dikenali

Analisis Struktural Lirik Input:

- Total Baris: 2 baris
- Total Kata: 10 kata
- Total Karakter: 60 karakter
- Tanda Baca: 0 simbol

Kesimpulan Model: Berdasarkan pembobotan kata dan kompleksitas strukturnya, emosi lirik ini paling didominasi oleh nuansa Rindu/Nostalgia.

Gambar 4.8 Tampilan Hasil Analisis Sentimen Lirik

Model Multinomial Naive Bayes, matriks bobot TF-IDF Vectorizer, dan skala MinMaxScaler yang telah dilatih pada Google Colab diekspor ke dalam format objek Serialization (.pkl). Ketika pengguna memasukkan teks lirik baru ke dalam antarmuka, sistem akan secara real-time melakukan ekstraksi Fitur Struktural (menghitung baris, kata, karakter, dan interaksi) serta pembobotan Fitur Teks (TF-IDF N-Grams) untuk membentuk 1005 fitur gabungan (Feature Fusion). Matriks tersebut kemudian dieksekusi oleh model untuk menghasilkan probabilitas emosi yang langsung divisualisasikan menggunakan Radar Chart interaktif.

Implementasi ini membuktikan bahwa rekayasa fitur yang dirancang tidak hanya beroperasi secara statis di dalam notebook eksperimen, tetapi juga adaptif dan responsif dalam memproses data lirik baru (Data Unseen) di lingkungan produksi sesungguhnya.

BAB V: KESIMPULAN

Berdasarkan hasil analisis dan pembahasan yang telah dipaparkan pada bab sebelumnya, dapat disimpulkan beberapa hal sebagai berikut:

1. Proyek rekayasa fitur dan pengolahan data teks (NLP) telah berhasil diimplementasikan untuk mengekstraksi sentimen multi-label pada lirik lagu Juicy Luicy. Model Multinomial Naive Bayes (MNB) yang mengkombinasikan fitur teks (TF-IDF) dan fitur struktural menunjukkan kinerja yang baik dengan tingkat kesalahan prediksi (*Hamming Loss*) yang rendah sebesar 0.1580 dan *F1-Score (Micro)* 0.6656.
2. Karakteristik emosional pada album "Sentimental" terbukti memiliki muatan yang sangat pekat dan spesifik, dimana hampir seluruh komposisi lagunya didominasi secara tajam oleh sentimen rindu, nostalgia, dan memori masa lalu.
3. Karakteristik emosional pada album "Non Fiksi" memperlihatkan gaya penulisan lirik yang lebih dinamis dan naratif. Sebaran komposisi emosinya terpecah lebih merata ke dalam berbagai nuansa, termasuk kategori harapan (*wondering*), kecewa/marah, hingga netral.
4. Dalam proses teknisnya, metode *Zero-Shot Classification* terbukti efisien sebagai solusi pelabelan otomatis (*annotating*) pada dataset mentah. Namun, kinerja model sangat sensitif terhadap ketidakseimbangan kelas (*imbalanced data*), yang berdampak pada rendahnya akurasi (*Recall*) untuk emosi minoritas.

Dari temuan-temuan tersebut, dapat disimpulkan bahwa Juicy Luicy secara konsisten mempertahankan identitas musik pop-melankolisnya, namun album "Sentimental" dirancang sebagai karya dengan fokus emosi kesedihan yang jauh lebih tajam dan mendalam dibandingkan dengan album "Non Fiksi" yang menawarkan variasi narasi cerita yang lebih luas.

Sebagai sarana pengembangan penelitian selanjutnya, direkomendasikan untuk mengimplementasikan teknik penanganan ketidakseimbangan data (seperti *oversampling* SMOTE atau penyesuaian bobot kelas) pada tahap pra-pemrosesan. Selain itu, penggantian pendekatan *Bag-of-Words* dengan model *Deep Learning*

berbasis urutan kalimat (seperti arsitektur IndoBERT), serta perluasan volume dataset dari musisi bergenre serupa, sangat disarankan agar model mampu mengklasifikasikan metafora lirik yang implisit dengan tingkat akurasi yang lebih optimal.